AUTORIDADE SINTÉTICA NA IA GENERATIVA E EXPLICABILIDADE COMO DIREITO: UMA REVISÃO DE ESCOPO

Synthetic authority in generative AI and explainability as a right: a scoping review

[Nome do autor], [Instituição], [e-mail]

RESUMO

Esta revisão de escopo tem por objetivo compreender como a literatura sobre autoridade cognitiva e autoridade epistêmica permite interpretar a autoridade que os usuários atribuem à inteligência artificial generativa e em que condições a explicabilidade possibilita examinar e contestar suas respostas, tendo o protocolo sido registrado antes das buscas e conduzido conforme o JBI e o PRISMA-ScR. Foram identificados 1.473 registros em BRAPCI, OpenAlex, Google Acadêmico, rastreamento de citações e busca nominal dirigida; após deduplicação e triagem, 68 textos foram avaliados e 55 estudos foram incluídos, abrangendo o período de 1983 a 2026. Os resultados indicam que a autoridade cognitiva vem sendo concebida em quatro linhas de investigação e que a autoridade epistêmica exige competência, boa-fé e justificação da deferência, condições que sistemas de IA não satisfazem isoladamente, ao passo que o termo autoridade sintética se mostra incipiente, disperso e majoritariamente veiculado em preprints de 2025-2026. As evidências experimentais indicam que explicações não reduzem a dependência excessiva por si mesmas, e o direito à explicação se apresenta fragmentado entre o Regulamento Geral de Proteção de Dados, o artigo 86 do Regulamento Europeu de IA e o artigo 20 da LGPD. Na discussão, refina-se a definição de autoridade sintética como conceito descritivo, distinguem-se quatro planos de análise e especifica-se a explicabilidade como direito em cinco dimensões acopladas à contestação, concluindo-se que, na educação, a explicação só converte autoridade em autonomia quando é contrastiva, informa a proveniência e se submete a procedimentos de revisão humana.

Palavras-chave: autoridade cognitiva; autoridade epistêmica; inteligência artificial generativa; explicabilidade; direito à explicação; educação.

1 INTRODUÇÃO

Quando uma resposta gerada por IA deixa de ser apenas uma informação a considerar e passa a funcionar, para o usuário, como razão suficiente para acreditar em algo?

Um estudante consulta um assistente conversacional sobre o contexto histórico de um tratado e recebe, em poucos segundos, uma resposta fluente, com datas, nomes e uma justificativa breve, diante da qual encerra a busca sem abrir a fonte citada, sem comparar versões e sem perguntar por que aquela resposta e não outra, de modo que a informação deixa de ser tratada como hipótese a testar e passa a operar como razão. O episódio, tomado em sua banalidade cotidiana, não se reduz a uma falha individual de atenção, pois indica que uma tecnologia de linguagem passou a ocupar a posição que a tradição epistemológica reserva às autoridades, isto é, aquelas fontes cuja palavra dispensa verificação porque se supõe que saibam o que dizem e que, por isso mesmo, podem ser invocadas como fundamento do que se acredita.

Como a literatura sobre autoridade cognitiva e autoridade epistêmica ajuda a compreender a autoridade atribuída à IA generativa, e em que condições a explicabilidade permite examinar e contestar suas respostas? Essa pergunta exige duas operações analíticas que a literatura frequentemente confunde: a primeira, de natureza descritiva, busca entender o que o usuário efetivamente faz quando trata uma resposta como razão, enquanto a segunda, de natureza normativa, procura verificar se essa atribuição preserva as condições que a tornariam justificada, distinção que organiza tanto a revisão quanto a proposta apresentada ao final.

Na Ciência da Informação, esse primeiro movimento foi descrito como julgamento de qualidade e de autoridade, distinto do simples acesso à informação, pois, conforme Rieh (2002, p. 145), os usuários realizam julgamentos preditivos, antes do contato com o objeto informacional, e avaliativos, durante e após a leitura, apoiando-se em características do objeto, da fonte, do conhecimento prévio, da situação e da posição ocupada nos resultados de busca; na psicologia da automação, o segundo movimento foi descrito como confiança e dependência, com ênfase nos riscos decorrentes do uso indevido de sistemas que erram (Parasuraman; Riley, 1997); e, na interação humano-computador, acrescentou-se a medida comportamental, uma vez que as pessoas aceitam sugestões algorítmicas incorretas com frequência e que intervenções capazes de forçar o engajamento reduzem essa aceitação (Buçinca; Malaya; Gajos, 2021, p. 1).

Ainda que esses programas descrevam disposições, vieses e comportamentos com precisão crescente, raramente nomeiam o status que o usuário confere ao sistema, pois dizer que alguém confia em uma ferramenta não equivale a dizer que a toma por autoridade, assim como dizer que compreendeu uma explicação não equivale a dizer que pode contestá-la. É nessa lacuna que o presente artigo se situa, recorrendo a duas tradições

que enfrentaram o problema de modo direto, a saber, a autoridade cognitiva, formulada por Wilson (1983) e desenvolvida no campo da Ciência da Informação, e a autoridade epistêmica, discutida na epistemologia social por Goldman (2001) e Zagzebski (2012), sem tratá-las como sinônimos, mas preservando as diferenças de escopo, de método e de pretensão normativa que as separam.

Nos últimos anos, a literatura sobre IA generativa passou a produzir rótulos próprios para o fenômeno, entre os quais a autoridade sintética (Startari, 2025), a autoridade epistêmica algorítmica (Palese, 2026), a autoridade cognitiva híbrida (Sun; Xu, 2025) e a propensão a conferir autoridade a algoritmos, designada como algority (Milella; Cabitza, 2026), o que sugere que os rótulos são novos, embora a pergunta que eles tentam responder seja antiga e reconhecível nas duas tradições mencionadas. A hipótese de trabalho adotada nesta revisão, a ser examinada e refinada na discussão, é a seguinte:

Autoridade sintética é a autoridade atribuída a um sistema de IA generativa quando o usuário toma sua resposta como razão suficiente para formar ou revisar uma crença. Essa atribuição pode se apoiar em sinais produzidos na interação, como fluência, segurança e capacidade de oferecer justificativas, mesmo quando esses sinais dizem pouco sobre a origem da afirmação ou a qualidade das evidências que a sustentam.

Ao longo do texto, procuramos reconstruir as duas tradições preservando suas diferenças, mapear os usos de autoridade sintética, distinguir quatro planos que a literatura costuma tratar como equivalentes (a percepção de competência, a deferência efetiva, a confiança epistemicamente justificada e o acerto da resposta), especificar a explicabilidade como direito em cinco dimensões e tomar a educação como campo prioritário de aplicação, por ser o lugar em que a deferência é aprendida e em que a explicação pode, ou não, converter-se em autonomia intelectual.

2 MÉTODO

2.1 Protocolo e pergunta estruturada

A revisão seguiu a metodologia do JBI para revisões de escopo (Peters et al., 2020) e as orientações de relato do PRISMA-ScR (Tricco et al., 2018), tendo sido registrado, antes da execução das buscas definitivas, um protocolo datado de 11 de novembro de 2026, no qual se definiram a pergunta estruturada em população, conceito e contexto (PCC), os critérios de elegibilidade, os idiomas, o período, os tipos de publicação e os procedimentos de triagem, extração e síntese. Duas alterações foram registradas com data e justificativa: a substituição da Web of Science pela OpenAlex como fonte bibliográfica internacional, em razão da indisponibilidade de assinatura institucional, e a redução do limite de exames por consulta no Google Acadêmico de vinte para dez resultados, em razão do bloqueio automatizado por captcha.

A população compreende usuários de IA generativa e de sistemas automatizados de informação e decisão, além de titulares de direitos afetados por decisões automatizadas; o conceito abrange autoridade cognitiva, autoridade epistêmica, autoridade sintética, credibilidade, confiança, deferência, dependência excessiva, explicabilidade, interpretabilidade, direito à explicação e contestabilidade; e o contexto reúne IA generativa e modelos de linguagem, apoio à decisão e educação superior e básica, com atenção às realidades brasileira e europeia. Foram incluídos estudos em português, inglês e espanhol, publicados entre 1983 e 2026, de qualquer desenho, desde que discutissem autoridade, credibilidade, confiança, deferência, explicabilidade ou contestabilidade, e excluídos os registros sem relação central com o tema, as contribuições exclusivamente técnicas, as duplicatas, os textos sem resumo acessível, os metadados não verificáveis e os comentários sem argumentação, critérios codificados de E1 a E6 e aplicados em duas etapas.

2.2 Fontes, expressões e limites de recuperação

As buscas foram organizadas em três frentes: fundamentos da autoridade (cognitive authority, epistemic authority, autoridade cognitiva e autoridade epistêmica), autoridade atribuída à IA (synthetic authority, autoridade sintética e combinações de autoridade, credibilidade, confiança e deferência com generative AI, large language model, LLM e IA generativa) e explicabilidade e direitos (explainable AI, XAI e explicabilidade, combinados com right to explanation, direito à explicação, contestabilidade e termos de educação), tendo a sintaxe sido adaptada a cada fonte após a realização de buscas-piloto, de modo a respeitar as especificidades dos campos de busca e dos operadores booleanos disponíveis.

A BRAPCI foi consultada por interface web, com nove expressões e recuperação integral dos resultados, totalizando 49 registros; a OpenAlex foi consultada por interface de programação, com oito expressões, busca no título e no resumo e limite de duzentos registros por consulta ordenados por relevância, totalizando 1.219 registros; o Google Acadêmico foi consultado por navegador, com oito expressões e exame dos dez primeiros resultados de cada uma, totalizando oitenta registros; o rastreamento de citações partiu de Hirvonen, Multas e Nygård (2025) e de Wachter, Mittelstadt e Floridi (2017), com exame de até quarenta

citações e quarenta referências por semente, totalizando 106 registros; e uma busca nominal dirigida recuperou dezenove obras fundacionais e fontes normativas primárias que não apareciam nos conjuntos anteriores. Todas as consultas foram registradas com fonte, data, expressão exata, campos, filtros, ordenação, total exibido e números efetivamente recuperados e examinados, conforme a planilha auditável que acompanha este artigo.

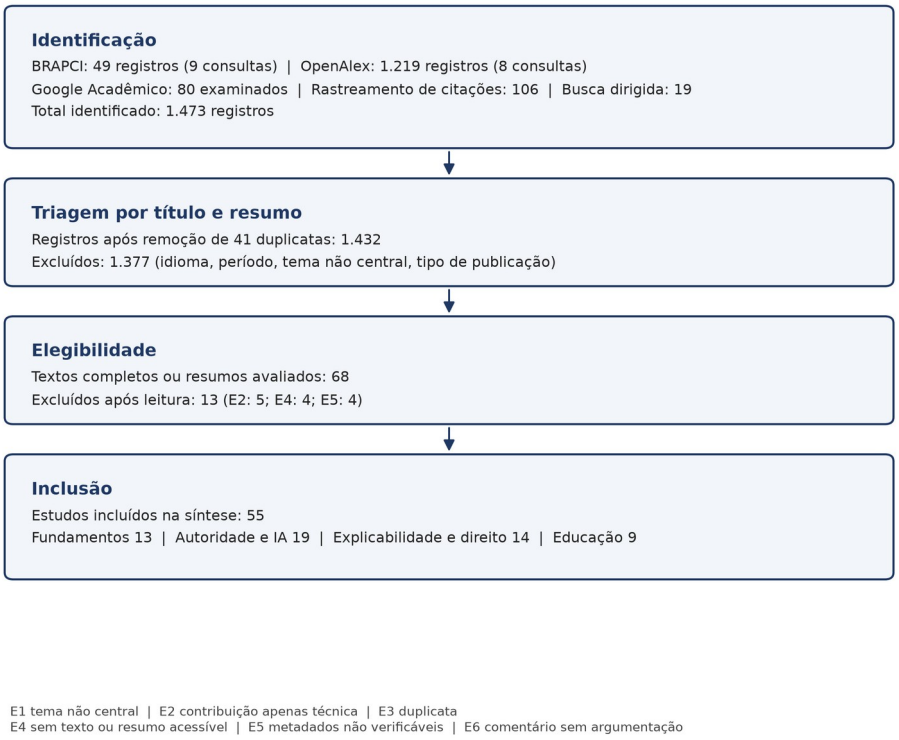
Cabe registrar que a busca na Web of Science permanece pendente, pois a base exige assinatura institucional indisponível no momento da execução, razão pela qual a OpenAlex foi adotada como substituta, com alteração de protocolo datada e justificada; essa pendência limita a cobertura da literatura indexada apenas naquele índice e será retomada nas limitações, de modo que a síntese aqui apresentada deve ser lida como preliminar quanto à cobertura bibliográfica.

2.3 Triagem, extração e síntese

Os 1.268 registros recuperados nas duas bases bibliográficas foram deduplicados por identificador digital e por similaridade de título, resultando em 1.227 registros únicos, com remoção de 41 duplicatas; em seguida, a triagem por título e resumo excluiu 1.377 registros no conjunto total, por idioma, período, tipo de publicação ou ausência de relação central com o tema, restando 68 textos completos ou resumos, dos quais treze foram excluídos após leitura (cinco por contribuição exclusivamente técnica, quatro por ausência de texto ou resumo acessível e quatro por metadados não verificáveis), o que resultou em 55 estudos, assim distribuídos: fundamentos (13), autoridade e IA (19), explicabilidade e direito (14) e educação (9).

A extração foi realizada em planilha com campos para referência, contexto, tipo de estudo, conceitos, definições, achados, limitações, localização exata da evidência e afirmação sustentada no artigo, sendo que a coluna de localização registra a página da versão consultada quando havia paginação e a seção, o resumo ou o título quando a consulta se deu em HTML ou apenas no resumo, distinção que se impõe porque, em vinte dos 55 estudos, a evidência disponível era o resumo, de modo que as afirmações a eles atribuídas se limitam ao que esse resumo permite verificar. A síntese foi narrativa, organizada por frentes temáticas, e o número real de revisores foi um, sem dupla triagem independente, limitação registrada no protocolo e retomada adiante; a Figura 1 apresenta o fluxo de seleção, com contagens conciliadas com as abas de triagem, leitura integral e extração da planilha.

Figura 1. Fluxo de seleção dos estudos (PRISMA-ScR)



Fonte: elaboração própria a partir dos registros da revisão.

2.4 Ciência aberta e disponibilidade dos materiais

A revisão foi conduzida de modo que terceiros possam refazer o percurso e contestar as decisões, e não apenas verificar os resultados. O protocolo foi redigido antes das buscas definitivas, na versão 1.0 de 11 de novembro de 2026, e registra a pergunta, os critérios de elegibilidade, as expressões por fonte, o limite de resultados examinados em cada consulta do Google Acadêmico e as buscas pendentes por restrição de acesso. Todos os materiais que sustentam os resultados estão depositados em repositório público, com versão identificada: as expressões exatas e os totais por consulta, os arquivos de registros recuperados, a lista de duplicatas removidas, as decisões de triagem, a matriz de extração com localizadores de página, as figuras em resolução de publicação e os scripts que geram a planilha e o diagrama de seleção. O texto, os dados e as figuras são licenciados sob CC BY 4.0 e os scripts, sob licença MIT, de modo que a reutilização exige apenas a atribuição e a indicação de eventuais alterações.

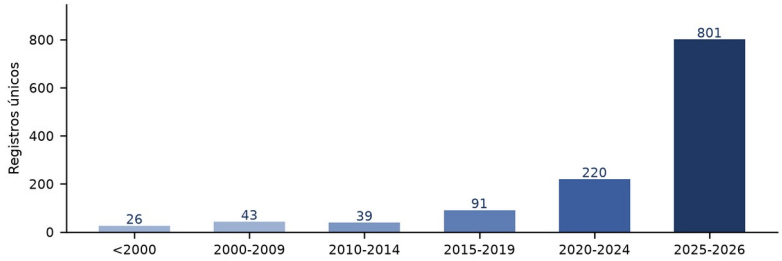
3 RESULTADOS

3.1 Perfil do corpus

O intervalo temporal dos 55 estudos incluídos vai de 1983 a 2026, com concentração acentuada nos dois últimos anos, concentração que não decorre de um recorte artificial da amostra final, pois, no conjunto de 1.227 registros únicos triados, 801 (65,3%) foram publicados em 2025 ou 2026, 220 entre 2020 e 2024 e 199 antes de 2020, como se observa na Figura 2.

Além disso, 253 registros (20,6%) provinham de repositórios de preprint ou de publicação não revisada por pares, com destaque para Zenodo (91), SSRN (78) e arXiv (29), o que indica que parte das definições mais recentes sobre autoridade atribuída à IA circula sem revisão por pares, ampliando a variabilidade terminológica e reduzindo a estabilidade das definições que o campo utiliza.

Figura 2. Distribuição dos 1.227 registros únicos triados por período de publicação



Fonte: elaboração própria.

3.2 Autoridade cognitiva: quatro linhas e três propriedades

A definição fundadora é a de Wilson (1983, p. 13, apud Hirvonen; Multas; Nygård, 2025, seção 1), para quem tudo o que sabemos além da estreita faixa da experiência própria é conhecimento de segunda mão, ou hearsay, sendo as autoridades cognitivas as fontes que influenciam o pensamento das pessoas e que são consideradas críveis; o ponto decisivo da formulação é negativo, pois essa autoridade não se funda no status como poder administrativo, mas na reputação e na expertise percebida da fonte (Wilson, 1983, p. 13, apud Hirvonen; Multas; Nygård, 2025, seção 1).

A revisão de escopo de 25 anos sobre o conceito identificou 235 referências e incluiu quarenta artigos, organizando a produção em quatro linhas paralelas: a autoridade cognitiva como indicador de qualidade da fonte, como construção discursiva, como fenômeno situado em mecanismos e cenários sociais e como legitimidade institucional da ciência e das profissões (Hirvonen; Multas; Nygård, 2025, resumo; seção 4), linhas que respondem a perguntas distintas e que, por isso, coexistem no campo.

A primeira linha, mais próxima dos estudos de usuário, mostrou que os julgamentos se dividem em preditivos e avaliativos e que dependem de características do objeto informacional, da fonte, do conhecimento do usuário, da situação, da posição no ranking de resultados e de suposições gerais (Rieh, 2002, p. 145); a segunda deslocou a análise para a justificação, ao examinar as estratégias discursivas com que buscadores de informação justificam suas decisões de autoridade, tratando a atribuição como algo narrado e negociado, e não apenas calculado (McKenzie, 2003); e a terceira insistiu no caráter situado e institucional do fenômeno, uma vez que critérios de relevância e autoridade são específicos de domínios e comunidades epistêmicas (Hjørland, 2002) e que a credibilidade se constitui como constructo multidimensional articulando fonte, mensagem e verificação (Rieh; Danielson, 2007), enquanto, no Brasil, Rocha e Gandra (2018) sistematizam os elementos constituintes

das práticas informacionais, noção mobilizada para descrever a relação entre sujeito, contexto e critérios de relevância.

A quarta linha, de natureza crítica, aproxima a autoridade do poder, pois, na perspectiva de Savolainen (2022), a autoridade cognitiva deve ser tratada como instância de poder informacional e de poder especializado, o que desloca a atenção da relação interpessoal para as estruturas que distribuem o direito de ser ouvido; Fricker (2007) fornece o complemento necessário a essa leitura, ao mostrar que a credibilidade atribuída aos falantes é mediada por relações de poder e que a injustiça epistêmica consiste precisamente em negar credibilidade por razões que não dizem respeito à competência, quadro que vem sendo aplicado a práticas concretas, como a construção de autoridade cognitiva por estudantes de Direito em ambientes digitais e de IA (Golenko; Kolarić; Martinović, 2026).

Do conjunto, emergem três propriedades que interessam diretamente a este artigo: a autoridade cognitiva é relacional, porque existe na atribuição e não no objeto; é dependente de domínio, porque os critérios variam entre comunidades epistêmicas; e é discursivamente justificável, porque os sujeitos precisam tornar suas decisões inteligíveis para si e para os outros. Tais propriedades antecipam o problema da IA generativa, na medida em que um sistema capaz de produzir linguagem pode exibir os sinais que sustentam a atribuição sem dispor das condições que a justificariam.

3.3 Autoridade epistêmica: o problema da justificação

A epistemologia social formula o problema em termos normativos, pois, segundo Goldman (2001), o leigo precisa identificar especialistas sem poder avaliar o conteúdo da expertise, o que exige critérios indiretos como a argumentação apresentada, a evidência disponível, o histórico e o consenso; Hardwig (1985) radicaliza o diagnóstico ao sustentar que a dependência de testemunhos não é defeito a corrigir, mas condição estrutural do conhecimento moderno; e Zagzebski (2012) oferece a formulação mais exigente, ao defender que a razão da autoridade preempta as razões do sujeito e que essa substituição se justifica pela confiança na competência e na boa-fé da fonte (Zagzebski, 2012, apud Ferrario; Facchini; Termine, 2024, seção 5).

A transposição desse quadro para sistemas artificiais é o que a literatura recente debate, e a posição mais nítida é a de Ferrario, Facchini e Termine (2024, resumo), para quem não é possível dotar sistemas de IA de expertise epistêmica genuína, porque a expertise exige uma relação com a compreensão e com habilidades intelectuais que o sistema não mantém; quando um sistema é apropriado com sucesso por um usuário humano, emerge um agente híbrido que pode ser especialista e autoridade, conclusão que os autores enunciam de modo explícito ao afirmarem que a capacidade de gerar previsões acuradas não basta para atribuir expertise ou autoridade epistêmica (Ferrario; Facchini; Termine, 2024, seção 5).

Hauswald (2025, seção 1) define autoridades epistêmicas como pessoas epistemicamente superiores em domínios particulares, capazes de fornecer crenças verdadeiras, conhecimento e compreensão, e examina se modelos de linguagem podem ocupar esse papel, registrando trocas em que o sistema fornece conhecimento proposicional, reformula explicações e responde a perguntas de acompanhamento, experimento conceitual que separa duas coisas frequentemente confundidas: o sistema pode produzir bens epistêmicos em alguns casos e, ainda assim, não satisfazer a condição de autoridade, que é relacional e normativa.

A evidência empírica mais próxima do fenômeno vem de Milella e Cabitza (2026), que propõem o conceito de algority, entendido como a propensão a conferir autoridade epistêmica a algoritmos, e o medem em 610 participantes, tendo a confiança na automação se revelado o principal preditor da atribuição, ao passo que atitudes morais moderaram a deferência em cenários sensíveis, como justiça criminal e seleção de pessoal; os autores concluem que nem a confiança na automação nem o desempenho percebido bastam para substituir o julgamento de especialistas (Milella; Cabitza, 2026, resumo). O estudo tem limites declarados (participantes universitários com menos de trinta anos, na Itália), mas estabelece o ponto central para esta revisão: a autoridade atribuída se apoia em confiança, não em verificação.

A diferença entre as duas tradições pode, então, ser enunciada com precisão: a autoridade cognitiva descreve uma relação social de influência epistemicamente relevante, cuja formação interessa à Ciência da Informação, enquanto a autoridade epistêmica descreve uma relação normativa, cuja justificação interessa à epistemologia, de modo que a primeira pergunta como a autoridade se forma e a segunda pergunta se ela é devida. Confundir as duas produz erros simétricos, pois ou se trata a atribuição como se fosse justificação, ou se exige de toda atribuição uma justificação que a vida epistêmica cotidiana não comporta.

3.4 Autoridade sintética: usos dispersos de um termo em formação

O mapeamento do termo produziu um resultado que merece ser registrado com precisão, pois a expressão autoridade sintética não aparece em nenhum registro da BRAPCI, enquanto a expressão synthetic authority recuperou 29 registros na OpenAlex, com intervalo de 1928 a 2026, e aproximadamente 155 resultados no Google Acadêmico, conjunto que se mostra disperso porque inclui usos antigos e não relacionados, como um

artigo de 1928 sobre autoridade religiosa, e uma concentração recente de preprints e capítulos publicados entre 2025 e 2026, sem que se identifique, entre os textos recuperados, uma definição operacional compartilhada.

O uso mais explícito é o de Startari (2025), que introduz o conceito em uma leitura crítica do poder exercido por sistemas de IA, em perspectiva linguística e histórica, e descreve a autoridade sintética como uma gramática impessoal de poder, formulação sugestiva que, no entanto, permanece no plano da crítica cultural, pois não especifica quais condições permitem dizer que um sistema exerce autoridade nem como distingui-la de outras formas de influência.

Outros autores descrevem o mesmo fenômeno com rótulos distintos, como se verifica em Sun e Xu (2025), que propõem a autoridade cognitiva híbrida, definida como a coconstrução de conhecimento entre agentes humanos e de IA, e a subjetividade algorítmica, definida como comunicação gerada por IA que simula intenção sem cognição; em Palese (2026), que descreve o surgimento de uma verdade artificial, entendida como forma de governança epistêmica em que a produção e a validação do conhecimento se tornam funções infraestruturais de sistemas sociotécnicos; e em Shin (2026), para quem a verdade não é neutra nem universal, mas carregada de pressupostos normativos, vieses de dados e lógica institucional, com consequências para a autoridade epistêmica e para a verificação pública.

Na educação, o termo aparece associado à pergunta sobre se a IA generativa pode funcionar como autoridade epistêmica, como mostram Cooper, Tang e Rappa (2024), que examinam essa possibilidade no ensino superior a partir das reflexões de três formadores de professores e problematizam tanto a dificuldade de discernir a verdade quanto os dilemas éticos das plataformas, e Özer, Perc e Özçelik (2026), que argumentam que a fluência e a coerência dos modelos de linguagem tornam difícil determinar qual agente responde por resultados de aprendizagem e por textos acadêmicos, de modo que a delegação de avaliação e supervisão a sistemas algorítmicos erode a responsabilidade e a autoridade epistêmica humanas.

O balanço, portanto, é claro: o termo nomeia um problema reconhecido, mas ainda não constitui conceito operacional, pois não há definição compartilhada, não há medida e não há distinção explícita entre a atribuição que o usuário faz e a justificação que a sustentaria, sendo a exceção parcial o trabalho de Milella e Cabitza (2026), que medem a propensão a conferir autoridade epistêmica a algoritmos, embora o façam sob outro rótulo; é essa lacuna que a discussão a seguir procura preencher.

3.5 Explicabilidade, interpretabilidade, transparência e direito

A inteligência artificial explicável (XAI) designa o conjunto de métodos e técnicas que procuram tornar compreensíveis as previsões de modelos de aprendizado de máquina (Lipton, 2018, p. 1-2; Miller, 2019, seção 1), e a literatura distingue quatro coisas que o senso comum costuma tratar como uma só: a transparência, que diz respeito à disponibilidade de informação sobre o sistema, seu processo e seus dados; a interpretabilidade, que designa uma propriedade do modelo e que, conforme Lipton (2018), cobre propriedades distintas (simulabilidade, decomposição e transparência algorítmica), cuja pertinência depende do público e da finalidade; a explicabilidade, que designa a resposta a uma pergunta sobre por que determinado resultado ocorreu e que, segundo Miller (2019, seção 2.3), é contrastiva, seletiva e dependente de contexto, como demonstram a filosofia e a psicologia cognitiva; e o direito à explicação, que constitui remédio jurídico, com titulares, devedores e condições próprias.

A confusão entre esses planos tem consequências práticas, pois, se a explicabilidade é propriedade técnica, basta aperfeiçoar métodos, se é resposta a uma pergunta contrastiva, é preciso saber qual pergunta o usuário formula, e, se é direito, é preciso saber quem pode exigi-la e de quem; Rudin (2019, p. 1) leva a primeira posição ao limite ao defender que, em decisões de alto risco, modelos interpretáveis substituam explicações pós-hoc de caixas-pretas, porque explicações aproximadas podem ser enganosas, enquanto Selbst e Barocas (2018) mostram por que a explicabilidade é intuitivamente atraente e, ao mesmo tempo, insuficiente, já que explicações podem ser incompletas, enganosas ou inúteis para quem foi afetado, e Mittelstadt et al. (2016) organizam o pano de fundo ao distinguirem formas de opacidade técnica e organizacional.

A evidência experimental sobre os efeitos da explicação é, talvez, o ponto mais desconfortável para a proposta de explicabilidade como direito, pois Bansal et al. (2021, p. 1-2) verificaram que explicações não melhoraram o desempenho de equipes humano-IA e, em alguns casos, aumentaram a dependência excessiva; Buçinca, Malaya e Gajos (2021, p. 1) demonstram que pessoas aceitam sugestões incorretas com frequência e que intervenções de forçamento cognitivo reduzem essa aceitação, ainda que com custo de esforço; e Vasconcelos et al. (2023, p. 1) mostram que a dependência excessiva não diminui automaticamente com explicações, porque as pessoas decidem estrategicamente quando se engajar nelas, e que condições capazes de induzir engajamento reduzem a dependência.

Tais resultados não refutam a explicabilidade, mas delimitam sua função, uma vez que uma explicação pode operar em duas direções opostas: ela permite verificar evidências, compreender limites e contestar quando expõe a proveniência da afirmação, os dados mobilizados e as alternativas descartadas, e quando é formulada de modo contrastivo; e reforça a autoridade percebida quando oferece uma justificativa plausível, internamente coerente e não falseável, que aumenta a confiança sem aumentar a capacidade de verificação. A diferença entre

os dois casos não está no formato da explicação, mas em sua relação com a prova e com o procedimento de contestação, como sugerem Nannini (2024, resumo), ao sistematizar no quadro TEFT as tensões entre explicação significativa e proteção de segredos comerciais no Regulamento Europeu de IA, e Jongepier e Keymolen (2022, resumo), ao deslocarem a discussão do como para o porquê e ao vincularem a resposta à agência do afetado.

3.6 O direito à explicação: três ordenamentos, alcances distintos

O Regulamento Geral de Proteção de Dados da União Europeia assegura ao titular o direito de acesso à informação significativa sobre a lógica envolvida em decisões automatizadas, bem como sobre o significado e as consequências previstas desse tratamento (União Europeia, 2016, art. 15, § 1º, alínea h), e o artigo 22, § 1º, garante o direito de não se sujeitar a decisão baseada unicamente em tratamento automatizado que produza efeitos jurídicos ou afete significativamente o titular, exigindo o § 3º, quando a decisão for permitida, medidas de salvaguarda que incluam a intervenção humana, a possibilidade de expressar ponto de vista e a contestação da decisão (União Europeia, 2016, art. 22).

A interpretação desses dispositivos é disputada, pois Wachter, Mittelstadt e Floridi (2017, p. 1) sustentam que o regulamento não cria um direito autônomo a explicação, uma vez que a ambiguidade e o escopo limitado do artigo 22 comprometem a proteção efetivamente oferecida; os autores identificam três bases jurídicas distintas, a saber, o artigo 22 com o considerando 71, os deveres de notificação dos artigos 13 e 14 e o direito de acesso do artigo 15, e mostram que a tese do direito à explicação as confunde (Wachter; Mittelstadt; Floridi, 2017, p. 5), enquanto Goodman e Flaxman (2017) leem os mesmos dispositivos como portadores de um direito limitado, Kaminski (2018) propõe distinguir explicações do sistema e de decisões específicas, e Edwards e Veale (2017) argumentam que um direito individual não é o remédio adequado, sendo preferíveis obrigações de governança.

O Regulamento Europeu de IA acrescenta um direito próprio, com alcance delimitado, pois o artigo 86, § 1º, confere à pessoa afetada por decisão tomada pelo responsável pela implantação com base em sistema de alto risco do Anexo III, exceto os do ponto 2 daquele anexo, e que produza efeitos jurídicos ou afete significativamente sua saúde, segurança ou direitos fundamentais o direito de obter explicações claras e significativas sobre o papel do sistema no procedimento decisório e sobre os principais elementos da decisão adotada (União Europeia, 2024, art. 86, § 1º), ressalvando o dispositivo as exceções previstas no direito da União ou nacional e aplicando-se apenas na medida em que o direito não esteja previsto em outro instrumento (União Europeia, 2024, art. 86, §§ 2º e 3º), com vigência a partir de 2 de agosto de 2026 (União Europeia, 2024, art. 113), sendo que o considerando 56 classifica como de alto risco os sistemas usados na educação para admissão, alocação, avaliação de resultados de aprendizagem e monitoramento de comportamento em testes (União Europeia, 2024, considerando 56).

No Brasil, a Lei Geral de Proteção de Dados assegura ao titular o direito de solicitar a revisão de decisões tomadas unicamente com base em tratamento automatizado que afetem seus interesses, incluídas as decisões destinadas a definir perfil pessoal, profissional, de consumo e de crédito ou aspectos da personalidade (Brasil, 2018, art. 20, caput), obrigando o controlador, no § 1º, a fornecer informações claras e adequadas sobre critérios e procedimentos, observados segredos comercial e industrial, e permitindo à autoridade nacional, no § 2º, realizar auditoria para verificar aspectos discriminatórios quando o segredo for invocado (Brasil, 2018, art. 20, §§ 1º e 2º). O alcance é mais estreito que o europeu em um aspecto, pois exige decisão tomada unicamente com base em tratamento automatizado, e mais amplo em outro, ao prever revisão e auditoria administrativa, conforme sintetiza o Quadro 2, ao qual Chen (2026) acrescenta a proposta de medir a cadeia de contestabilidade, verificando se a pessoa consegue efetivamente contestar a decisão ao longo de todo o percurso, e não apenas se recebeu uma explicação.

Quadro 2. Direito à explicação em três ordenamentos: titulares, devedores, situações, conteúdo e meios

Dimensão	**RGPD (UE, 2016)**	**Regulamento de IA (UE, 2024)**	**LGPD (Brasil, 2018)**
Quem pode exigir	Titular de dados (arts. 15 e 22)	Pessoa afetada pela decisão (art. 86, § 1º)	Titular de dados (art. 20, caput)
De quem	Controlador (arts. 15 e 22)	Responsável pela implantação (art. 86, § 1º)	Controlador (art. 20, §§ 1º e 2º)
Em quais situações	Decisão unicamente automatizada com efeitos jurídicos ou impacto significativo (art. 22, § 1º)	Sistema de alto risco do Anexo III, exceto ponto 2, com efeitos jurídicos ou impacto significativo (art. 86, § 1º)	Decisão unicamente automatizada que afete interesses (art. 20, caput)
Sobre o quê	Lógica envolvida, significado e consequências previstas (art. 15, § 1º, h)	Papel do sistema no procedimento e principais elementos da decisão (art. 86, § 1º)	Critérios e procedimentos utilizados (art. 20, § 1º)
Com quais meios	Intervenção humana, expressão de ponto de vista e contestação (art. 22, § 3º)	Explicação clara e significativa, sem procedimento de contestação próprio no artigo	Revisão da decisão e auditoria pela autoridade nacional (art. 20, caput e § 2º)

Dimensão	RGPD (UE, 2016)	Regulamento de IA (UE, 2024)	LGPD (Brasil, 2018)
Limites	Interpretação disputada; ausência de direito autônomo (Wachter; Mittelstadt; Floridi, 2017, p. 1)	Restrito ao Anexo III; ressalvas de direito da União e nacional (art. 86, §§ 2º e 3º); vigência em 2 ago. 2026	Segredo comercial e industrial (art. 20, § 1º); alcance restrito a decisões unicamente automatizadas

Fonte: elaboração própria a partir das normas citadas e da literatura jurídica incluída na revisão.

3.7 Educação: onde a deferência é aprendida

A educação aparece na literatura por três portas, sendo a primeira o diagnóstico de campo, como se verifica na revisão sistemática de Zawacki-Richter et al. (2019, resumo), que partiu de 2.656 publicações do período de 2007 a 2018 e incluiu 146 artigos, concluindo que a pesquisa sobre aplicações de IA no ensino superior é fraca em perspectivas pedagógicas e em presença de educadores, e na revisão crítica de Bearman, Ryan e Ajjawi (2023, resumo), que encontrou poucas definições e definições confusas de IA nos principais periódicos de educação superior, além de dois discursos predominantes, um deles organizado em torno da mudança imperativa, retórica que Williamson e Eynon (2020) situam em trajetórias históricas mais longas, apontando lacunas de pesquisa sobre poder, dados e trabalho docente.

A segunda porta é a dos riscos epistêmicos, pois Kasneci et al. (2023, p. 1) discutem oportunidades e riscos dos modelos de linguagem na educação, incluindo respostas plausíveis e incorretas, dependência, viés e a necessidade de letramento crítico e de mediação docente; Cotton, Cotton e Shipway (2024, p. 1) analisam como o ChatGPT desafia a integridade acadêmica e propõem transparência sobre o uso e redesenho de tarefas; Perkins (2023, resumo) mostra que esses sistemas podem produzir texto original e coerente que evita detecção, problematizando a atribuição de autoria; Holmes et al. (2022, resumo) argumentam que intenções éticas não bastam e que equidade, responsabilidade, transparência, autonomia e inclusão precisam ser tratadas explicitamente no desenho; e Akgun e Greenhow (2022, resumo) ampliam o diagnóstico para a educação básica, incluindo avaliação automatizada e reconhecimento facial.

A terceira porta é a da autoridade, na qual Özer, Perc e Özçelik (2026, resumo) descrevem a delegação de avaliação e supervisão a sistemas algorítmicos como transformação estrutural que erode a responsabilidade e a autoridade epistêmica humanas e apontam riscos de falsos positivos nas ferramentas de detecção de IA, Cooper, Tang e Rappa (2024, resumo) colocam a pergunta diretamente ao indagarem se a IA generativa pode funcionar como autoridade epistêmica no ensino superior, Safarov, Gadzinski e Schlögl (2025, resumo) investigam como a explicabilidade de sistemas generativos e a expertise percebida afetam a confiança de usuários educacionais, e Golenko, Kolarić e Martinović (2026) examinam como estudantes de Direito constroem autoridade cognitiva em ambientes digitais e de IA.

O que a literatura educacional ainda não oferece, contudo, é uma articulação entre esses três conjuntos, pois os estudos de integridade tratam da autoria, os de ética tratam do desenho e os de autoridade tratam da relação epistêmica, sem que os três se encontrem; a discussão a seguir propõe essa articulação, tomando a explicação como o dispositivo que pode, ou não, converter autoridade em autonomia.

4 DISCUSSÃO

4.1 A definição refinada

A definição de trabalho enunciada na introdução descreve corretamente o fenômeno, mas é ampla demais, pois qualquer informação considerada útil poderia satisfazê-la; por isso, a comparação entre as duas tradições e a evidência sobre dependência permitem especificar três condições que, quando presentes simultaneamente, caracterizam a autoridade sintética: a assimetria de acesso, isto é, a circunstância de o usuário não dispor de meio independente para verificar a afirmação no momento em que dela precisa; a presença de sinais que mimetizam garantia, como fluência, segurança, coerência interna, estrutura justificatória, citação de fontes plausíveis e adaptação ao interlocutor; e a ausência de procedimento de contestação, ou seja, a inexistência de instância a que recorrer e de critério para saber o que contaria como refutação.

A definição refinada é, portanto, a seguinte: autoridade sintética é a autoridade de fato atribuída a um sistema de IA generativa quando sua resposta é tomada pelo usuário como razão suficiente para formar ou revisar uma crença, em condições de assimetria de verificação, de sinais que mimetizam garantia epistêmica e de ausência de procedimento de contestação; trata-se de definição descritiva, e não normativa, pois não afirma que o sistema tenha autoridade, mas que a atribuição ocorre e pode ser identificada por suas condições.

Duas consequências decorrem dessa formulação: a autoridade sintética é graduável, porque, quanto maior a assimetria, mais eficazes os sinais e menor a possibilidade de contestação, mais intensa será a atribuição; e é independente do acerto, porque uma resposta correta pode ser aceita por autoridade e uma resposta incorreta pode ser rejeitada por verificação, independência que a literatura empírica sobre dependência excessiva demonstra e que a seção 4.4 detalha.

4.2 Três formas de autoridade

O Quadro 1 compara as três formas: a autoridade cognitiva, relação social de influência epistemicamente relevante, fundada em reputação e expertise percebida, adquirida por trajetória e reconhecimento, corrigida pela comunidade e contestada pela crítica de fontes; a autoridade epistêmica, relação normativa, fundada em competência e boa-fé, adquirida por formação e prática, corrigida pela justificação e contestada pela demonstração de erro ou de má-fé; e a autoridade sintética, tal como aqui proposta, relação de atribuição, fundada em sinais de interface, adquirida pela interação, sem critério interno de correção e contestável apenas por procedimentos externos de verificação.

Quadro 1. Três formas de autoridade: fundamento, aquisição, correção e contestação

Dimensão	**Autoridade cognitiva**	**Autoridade epistêmica**	**Autoridade sintética**
Fonte da autoridade	Reputação e expertise percebida (Wilson, 1983, p. 13)	Competência e boa-fé, com justificação da deferência (Zagzebski, 2012)	Sinais da interação: fluência, segurança, justificativa plausível
Base da deferência	Reconhecimento social e comunitário (Hirvonen; Multas; Nygård, 2025, seção 4)	Preempção justificada das razões do sujeito (Ferrario; Facchini; Termine, 2024, seção 5)	Percepção de competência sem acesso à verificação (Milella; Cabitza, 2026)
Como se adquire	Trajetória, credenciais e reconhecimento do domínio (Hjørland, 2002)	Formação, prática e prestação de contas epistêmica (Goldman, 2001)	Uso reiterado e adaptação ao interlocutor (Özer; Perc; Özçelik, 2026)
Critério de correção	Avaliação pela comunidade e crítica de fontes (Rieh, 2002, p. 145)	Justificação pública e falseabilidade (Hardwig, 1985)	Não há critério interno; depende de verificação externa
Falha característica	Atribuição indevida a fontes com prestígio e sem competência (Fricker, 2007)	Deferência injustificada a especialistas ou a quem se apresenta como tal	Dependência excessiva e aceitação de erro plausível (Buçinca; Malaya; Gajos, 2021, p. 1)
Como se contesta	Crítica pública, comparação entre fontes, revisão por pares	Argumentação, evidência contrária, revisão de crença	Explicação contrastiva com proveniência e procedimento de revisão

Fonte: elaboração própria a partir dos estudos incluídos. As três colunas não são estágios evolutivos nem formas substitutas: coexistem e frequentemente se sobrepõem na mesma interação.

4.3 O que a proposta explica e o que não explica

A proposta explica três coisas que os conceitos existentes deixam em segundo plano: a formação da deferência sem verificação, pois a autoridade sintética nomeia a conferência e não a qualidade do sistema, descrevendo casos em que a confiança cresce enquanto a capacidade de verificação permanece constante ou diminui; a eficácia dos sinais de superfície, pois fluência e segurança funcionam como substitutos de garantia porque são lidas como indícios de competência, leitura plausível nas interações humanas e que explica sua persistência nas interações com máquinas; e a ambivalência da explicação, que, se é sinal a mais, reforça a autoridade, e, se é instrumento de verificação, pode reduzi-la.

A proposta não substitui os conceitos existentes, pois a credibilidade permanece um constructo multidimensional que descreve a percepção de qualidade de fontes e mensagens (Rieh; Danielson, 2007; Flanagin; Metzger, 2007), a confiança permanece uma atitude que orienta a dependência e cujo desenho apropriado é uma questão de interação (Lee; See, 2004), o viés de automação permanece um padrão de erro documentado, com frequência e mediadores próprios (Skitka; Mosier; Burdick, 1999; Goddard; Roudsari; Wyatt, 2012), e a dependência excessiva permanece um comportamento mensurável (Buçinca; Malaya; Gajos, 2021, p. 1), de modo que a autoridade sintética é uma categoria adicional, que descreve o status conferido e as condições em que ele se forma.

Também é preciso delimitar o que a proposta não explica (a persuasão retórica em sentido estrito, a formação de bolhas informacionais e a autoridade institucional de organizações que produzem e certificam sistemas), assim como não estabelece que a atribuição seja epistemicamente justificada, pois a definição é compatível com a tese de que, em muitos casos, ela não é: Ferrario, Facchini e Termine (2024, seção 5) fornecem a razão de princípio, ao negarem expertise epistêmica genuína a sistemas que não mantêm relação com a compreensão, e Milella e Cabitza (2026, resumo) fornecem a razão empírica, ao mostrarem que a atribuição se apoia em confiança na automação e não em avaliação de desempenho.

Cabe explicitar, ainda, a divisão entre o que vem da literatura e o que constitui elaboração deste artigo, pois, da literatura, provêm as definições de autoridade cognitiva e epistêmica, a tipologia das quatro linhas, os conceitos de algority, autoridade cognitiva híbrida e verdade artificial, a distinção entre explicabilidade, interpretabilidade, transparência e direito à explicação, a evidência experimental sobre dependência excessiva e o conteúdo das normas citadas, enquanto constituem elaboração própria a definição de autoridade sintética em três

condições, a distinção dos quatro planos de análise, a especificação da explicabilidade como direito em cinco dimensões e a articulação entre autoridade sintética e autonomia intelectual na educação.

4.4 Quatro planos que a literatura confunde

A literatura sobre confiança e dependência frequentemente trata como equivalentes quatro coisas distintas: a percepção de competência, que corresponde ao que o usuário acredita sobre a capacidade do sistema e que é medida por julgamentos e escalas (Rieh, 2002, p. 145; Milella; Cabitza, 2026); a deferência efetiva, que corresponde ao que o usuário faz ao aceitar, seguir ou replicar a sugestão e que é medida por comportamento (Buçinca; Malaya; Gajos, 2021, p. 1; Vasconcelos et al., 2023, p. 1); a confiança epistemicamente justificada, que corresponde a saber se o usuário tem razões adequadas para deferir e cuja avaliação exige reconstruir as razões disponíveis (Ferrario; Facchini; Termine, 2024, seção 5); e o acerto da resposta, que corresponde a saber se a afirmação é verdadeira ou o resultado é correto e que é medido por comparação com padrão independente (Bansal et al., 2021, p. 1-2).

Os planos são independentes, e a confusão entre eles produz inferências inválidas, pois Dzindolet et al. (2003) mostram que a confiança declarada não prediz bem a dependência efetiva, o que separa o primeiro plano do segundo; Logg, Minson e Moore (2019) documentam a apreciação de algoritmos em tarefas de previsão, o que mostra que a percepção de competência pode ser alta mesmo quando o desempenho não é superior; Bansal et al. (2021, p. 1-2) e Vasconcelos et al. (2023, p. 1) mostram que explicações podem não alterar nem o comportamento nem o acerto; e Rudin (2019, p. 1) mostra que uma explicação plausível pode não corresponder ao que o modelo efetivamente faz, o que separa o terceiro plano da aparência de justificação.

A consequência metodológica é que a autoridade sintética não pode ser medida por um único instrumento, pois um estudo que mede apenas confiança declarada mede o primeiro plano, um que mede apenas aceitação mede o segundo e um que mede apenas acerto mede o quarto, de modo que somente a combinação de medidas comportamentais, normativas e factuais permite dizer se a autoridade atribuída é também justificada, combinação que a literatura sobre IA generativa ainda não produziu.

4.5 Explicabilidade como direito: cinco especificações

A explicabilidade como direito exige cinco especificações, sem as quais a exigência se torna retórica: a primeira é quem pode exigir, ou seja, o titular dos dados, no regime de proteção de dados, e a pessoa afetada pela decisão, no regime de IA (União Europeia, 2016, art. 15, § 1º; União Europeia, 2024, art. 86, § 1º; Brasil, 2018, art. 20, caput); a segunda é de quem, isto é, do controlador, no primeiro caso, e do responsável pela implantação, no segundo; e a terceira é em quais situações, a saber, decisões unicamente automatizadas com efeitos jurídicos ou impacto significativo, no RGPD, sistemas de alto risco do Anexo III, no Regulamento de IA, e decisões unicamente automatizadas que afetem interesses, na LGPD.

A quarta especificação é sobre o quê, e aqui a distinção entre explicação do sistema e explicação da decisão é decisiva (Kaminski, 2018), pois o RGPD exige informação sobre a lógica envolvida, o significado e as consequências previstas (União Europeia, 2016, art. 15, § 1º, alínea h), o Regulamento de IA exige o papel do sistema no procedimento e os principais elementos da decisão (União Europeia, 2024, art. 86, § 1º) e a LGPD exige critérios e procedimentos utilizados (Brasil, 2018, art. 20, § 1º); a quinta é com quais meios, prevendo o RGPD a intervenção humana, a expressão de ponto de vista e a contestação (União Europeia, 2016, art. 22, § 3º), a LGPD a revisão e a auditoria (Brasil, 2018, art. 20, caput e § 2º) e o Regulamento de IA a explicação sem procedimento próprio de contestação no artigo 86, lacuna que Chen (2026) procura corrigir ao propor a medida da cadeia de contestabilidade.

Dessas especificações decorre uma proposta: a de que o direito à explicação, para ser efetivo, deve ser um direito à explicação contestável, com três requisitos: o contraste, pois a explicação deve responder por que este resultado e não outro plausível, e não apenas descrever o funcionamento geral do sistema (Miller, 2019, seção 2.3); a proveniência, pois deve indicar de onde vêm as afirmações e quais evidências as sustentam; e o procedimento, pois deve estar acoplada a uma instância de revisão humana com poder de alterar a decisão, como exigem o artigo 22, § 3º, do RGPD e o artigo 20 da LGPD. Os limites, contudo, são reais, porque explicações pós-hoc podem ser enganosas (Rudin, 2019, p. 1), explicações completas podem ser incompatíveis com segredos comerciais (Nannini, 2024, resumo; Brasil, 2018, art. 20, § 1º) e um direito individual pode não ser o remédio mais eficaz para decisões estruturais (Edwards; Veale, 2017), de modo que a proposta não elimina esses limites, mas reposiciona a exigência ao vincular a explicação à possibilidade efetiva de discordar.

4.6 Educação: da autoridade à autonomia

A educação é campo prioritário por três razões que se articulam: é onde a deferência é aprendida, porque o estudante está estruturalmente na posição de quem depende de fontes que não pode verificar integralmente (Hardwig, 1985); é onde a autoridade é avaliada, porque a avaliação existe precisamente para

certificar o que o estudante sabe sem ajuda; e é onde a explicação tem função pedagógica, e não apenas jurídica, pois deve produzir compreensão e não conformidade.

A primeira tese é que a sala de aula se tornou um laboratório de autoridade sintética, pois, quando o estudante usa um modelo de linguagem para produzir um texto, resolver um problema ou resumir uma leitura, ele não apenas obtém informação, mas ensaia uma relação de deferência; se essa relação não for tematizada, o sistema se torna a autoridade padrão e a mediação docente perde função epistêmica (Özer; Perc; Özçelik, 2026, resumo; Cooper; Tang; Rappa, 2024, resumo). Os estudos sobre integridade acadêmica descrevem o sintoma, isto é, texto original e coerente que evita detecção (Perkins, 2023, resumo), mas o problema é anterior à fraude, pois consiste na substituição do juízo pelo resultado.

A segunda tese é que a explicação pedagógica não se confunde com a jurídica, porque a primeira responde ao afetado sobre os principais elementos de uma decisão já tomada (União Europeia, 2024, art. 86, § 1º), enquanto a segunda responde ao estudante sobre por que uma afirmação é sustentável, quais são seus limites e o que contaria como refutação, sendo, por natureza, contrastiva e falibilista (Miller, 2019, seção 2.3) e dependendo, para ser eficaz, do engajamento do estudante, como indicam as intervenções que forçam a comparação entre a resposta do sistema e alternativas e que reduzem a aceitação indevida (Buçinca; Malaya; Gajos, 2021, p. 1).

A terceira tese é que existe um dever institucional de explicar decisões automatizadas que afetam estudantes, pois o Regulamento de IA classifica como de alto risco os sistemas usados para admissão, alocação, avaliação de resultados e monitoramento de comportamento em testes (União Europeia, 2024, considerando 56), e o artigo 86 confere à pessoa afetada o direito a explicação clara e significativa, com vigência a partir de 2 de agosto de 2026, enquanto, no Brasil, o artigo 20 da LGPD assegura a revisão de decisões unicamente automatizadas e informações sobre critérios e procedimentos. A mediação docente é o mecanismo que converte esse direito em autonomia, pois, sem ela, a explicação informa o resultado, mas não ensina o estudante a avaliar o processo, o que implica redesenhar a avaliação para tornar visível o processo e não apenas o produto (Cotton; Cotton; Shipway, 2024, p. 1).

4.7 Limitações

A revisão tem limitações que afetam o alcance das conclusões, sendo a primeira a cobertura, pois a Web of Science não foi acessada por exigir assinatura institucional e a OpenAlex foi adotada como substituta, de modo que estudos indexados apenas naquele índice podem estar ausentes e a síntese deve ser lida como preliminar quanto à cobertura bibliográfica; a segunda é o limite de recuperação, pois o teto de duzentos registros por consulta na OpenAlex e o exame de dez resultados por consulta no Google Acadêmico restringiram o corpus; e a terceira é o número de revisores, pois houve um único revisor, sem dupla triagem independente, o que aumenta o risco de erro de seleção.

A quarta limitação é a profundidade da evidência, pois, em vinte dos 55 estudos, o texto completo não estava acessível e as afirmações a eles atribuídas se limitam ao que o resumo permite verificar; a quinta é a ausência de avaliação formal de qualidade metodológica, compatível com revisões de escopo, mas que impede ponderar os achados por robustez; a sexta é de natureza temporal, pois, como 65,3% dos registros triados foram publicados em 2025 ou 2026 e 20,6% circulam sem revisão por pares, parte do corpus está sujeita a mudança. A sétima é linguística, pois foram incluídos textos em português, inglês e espanhol, e a proposta conceitual da discussão é elaboração teórica apoiada na literatura, não resultado empírico, de modo que sua validade depende de operacionalização e teste em estudos próprios.

5 CONCLUSÃO

A pergunta inicial pode, agora, ser respondida com precisão: uma resposta gerada por IA deixa de ser informação a considerar e passa a funcionar como razão suficiente quando três condições se combinam: o usuário não tem meio independente de verificação, o sistema exibe sinais que mimetizam garantia epistêmica e a interação não oferece procedimento de contestação, e a autoridade sintética é o nome dessa combinação, cuja definição é descritiva, pois descreve o que ocorre e não o que seria justificado.

A literatura sobre autoridade cognitiva e autoridade epistêmica ajuda a compreender o fenômeno em dois sentidos, pois a primeira mostra que a autoridade é relacional, dependente de domínio e discursivamente justificada, e que sua atribuição é um fenômeno social antes de ser um cálculo de qualidade, enquanto a segunda mostra que a autoridade exige justificação da deferência e que essa justificação não se reduz ao desempenho, já que a capacidade de gerar respostas acuradas não basta para constituir expertise ou autoridade (Ferrario; Facchini; Termine, 2024, seção 5).

A explicabilidade, por sua vez, permite examinar e contestar respostas apenas sob condições específicas, pois precisa ser contrastiva, informar a proveniência das afirmações e estar acoplada a um procedimento de revisão com poder de alterar a decisão; sem essas três propriedades, pode aumentar a confiança

sem aumentar a capacidade de verificação e, nesse caso, reforça a autoridade em vez de limitá-la, conclusão consistente com a evidência de que explicações, por si, não reduzem a dependência excessiva (Bansal et al., 2021, p. 1-2; Vasconcelos et al., 2023, p. 1).

Na educação, o direito à explicação sobre decisões automatizadas que afetam estudantes existe e tem alcance delimitado, tanto no Regulamento Europeu de IA quanto na LGPD, mas o direito garante informação e não formação, pois esta depende de mediação docente, de tarefas que exijam justificação e da tematização da deferência como objeto de aprendizagem; a contribuição principal deste trabalho é, nesse sentido, modesta e necessária, pois consiste em separar a atribuição da justificação, uma vez que a autoridade sintética não é uma autoridade que os sistemas possuem, mas uma relação que os usuários produzem, sob condições que podem ser descritas, medidas e, em parte, modificadas. A agenda de pesquisa que decorre daí tem quatro entradas: operacionalizar a autoridade sintética em instrumentos que meçam separadamente os quatro planos; testar as três condições da definição em contextos educacionais, com desenhos longitudinais; comparar regimes jurídicos quanto à efetividade da contestação; e examinar a persuasão em sentido estrito, dimensão que a literatura recuperada trata de modo marginal e que a definição aqui proposta deliberadamente não cobre.

DISPONIBILIDADE DE DADOS E MATERIAIS

O protocolo, as expressões de busca com os totais por consulta, os registros recuperados, as decisões de triagem, a matriz de extração e os scripts de análise estão disponíveis em repositório público (https://github.com/brenohferreira/autoridade-sintetica), versão 1.0.0, sob licença CC BY 4.0 para textos, dados e figuras e MIT para código, com a lista de verificação PRISMA-ScR preenchida no mesmo depósito.

REFERÊNCIAS

AKGUN, S.; GREENHOW, C. Artificial intelligence in education: addressing ethical challenges in K-12 settings. AI and Ethics, v. 2, n. 3, p. 431-440, 2022. DOI: 10.1007/s43681-021-00096-7.

BANSAL, G. et al. Does the whole exceed its parts? The effect of AI explanations on complementary team performance. In: CHI CONFERENCE ON HUMAN FACTORS IN COMPUTING SYSTEMS, 2021. Proceedings [...]. New York: ACM, 2021. p. 1-16. DOI: 10.1145/3411764.3445717.

BEARMAN, M.; RYAN, J.; AJJAWI, R. Discourses of artificial intelligence in higher education: a critical literature review. Higher Education, v. 86, n. 2, p. 369-385, 2023. DOI: 10.1007/s10734-022-00937-2.

BRASIL. Lei nº 13.709, de 14 de agosto de 2018. Lei Geral de Proteção de Dados Pessoais (LGPD). Brasília: Presidência da República, 2018. Redação do art. 20 dada pela Lei nº 13.853/2019.

BUÇINCA, Z.; MALAYA, M. B.; GAJOS, K. Z. To trust or to think: cognitive forcing functions can reduce overreliance on AI in AI-assisted decision-making. Proceedings of the ACM on Human-Computer Interaction, v. 5, n. CSCW1, p. 1-21, 2021. DOI: 10.1145/3449287.

CHEN, X. Can people challenge an AI decision? Measuring the contestability chain in law and corporate disclosure. AI and Ethics, v. 6, n. 6, 2026. DOI: 10.1007/s43681-026-01471-y.

COOPER, G.; TANG, K. S.; RAPPA, N. A. Generative artificial intelligence as epistemic authority? In: Artificial intelligence applications in higher education. Londres: Routledge, 2024. p. 106-122. DOI: 10.4324/9781003440178-7.

COTTON, D. R. E.; COTTON, P. A.; SHIPWAY, J. R. Chatting and cheating: ensuring academic integrity in the era of ChatGPT. Innovations in Education and Teaching International, v. 61, n. 2, p. 228-239, 2024. DOI: 10.1080/14703297.2023.2190148.

DZINDOLET, M. T.; PETERSON, S. A.; POMRANKY, R. A.; PIERCE, L. G.; BECK, H. P. The role of trust in automation reliance. International Journal of Human-Computer Studies, v. 58, n. 6, p. 697-718, 2003. DOI: 10.1016/S1071-5819(03)00038-7.

EDWARDS, L.; VEALE, M. Slave to the algorithm? Why a 'right to an explanation' is probably not the remedy you are looking for. SSRN Electronic Journal, 2017. DOI: 10.2139/ssrn.2972855.

FERRARIO, A.; FACCHINI, A.; TERMINE, A. Experts or authorities? The strange case of the presumed epistemic superiority of artificial intelligence systems. Minds and Machines, v. 34, n. 3, art. 30, 2024. DOI: 10.1007/s11023-024-09681-1.

FLANAGIN, A. J.; METZGER, M. J. The role of site features, user attributes, and information verification behaviors on the perceived credibility of web-based information. New Media & Society, v. 9, n. 2, p. 319-342, 2007. DOI: 10.1177/1461444807075015.

FRICKER, M. Epistemic injustice: power and the ethics of knowing. Oxford: Oxford University Press, 2007. DOI: 10.1093/acprof:oso/9780198237907.001.0001.

GODDARD, K.; ROUDSARI, A.; WYATT, J. C. Automation bias: a systematic review of frequency, effect mediators, and mitigators. Journal of the American Medical Informatics Association, v. 19, n. 1, p. 121-127, 2012. DOI: 10.1136/amiajnl-2011-000089.

GOLDMAN, A. I. Experts: which ones should you trust? Philosophy and Phenomenological Research, v. 63, n. 1, p. 85-110, 2001. DOI: 10.1111/j.1933-1592.2001.tb00093.x.

GOLENKO, D.; KOLARIĆ, A.; MARTINOVIĆ, I. Law students' knowledge practices: construction of cognitive authority in challenging digital and AI environment. In: Communications in Computer and Information Science. Cham: Springer, 2026. p. 491-503. DOI: 10.1007/978-3-032-17272-3_39.

GOODMAN, B.; FLAXMAN, S. European Union regulations on algorithmic decision-making and a 'right to explanation'. AI Magazine, v. 38, n. 3, p. 50-57, 2017. DOI: 10.1609/aimag.v38i3.2741.

HARDWIG, J. Epistemic dependence. The Journal of Philosophy, v. 82, n. 7, p. 335-349, 1985. DOI: 10.2307/2026523.

HAUSWALD, R. Artificial epistemic authorities. Social Epistemology, v. 39, n. 6, p. 716-725, 2025. DOI: 10.1080/02691728.2025.2449602.

HIRVONEN, N.; MULTAS, A.-M.; NYGÅRD, T. Cognitive authority: a scoping review of empirical research. Journal of the Association for Information Science and Technology, v. 76, n. 1, p. 155-192, 2025. DOI: 10.1002/asi.24942.

HJØRLAND, B. Epistemology and the socio-cognitive perspective in information science. Journal of the American Society for Information Science and Technology, v. 53, n. 4, p. 257-270, 2002. DOI: 10.1002/asi.10042.

HOLMES, W. et al. Ethics of AI in education: towards a community-wide framework. International Journal of Artificial Intelligence in Education, v. 32, n. 3, p. 504-526, 2022. DOI: 10.1007/s40593-021-00239-1.

JONGEPIER, F.; KEYMOLEN, E. Explanation and agency: exploring the normative-epistemic landscape of the 'right to explanation'. Ethics and Information Technology, v. 24, n. 4, 2022. DOI: 10.1007/s10676-022-09654-x.

KAMINSKI, M. E. The right to explanation, explained. SSRN Electronic Journal, 2018. DOI: 10.2139/ssrn.3196985.

KASNECI, E. et al. ChatGPT for good? On opportunities and challenges of large language models for education. Learning and Individual Differences, v. 103, art. 102274, 2023. DOI: 10.1016/j.lindif.2023.102274.

LEE, J. D.; SEE, K. A. Trust in automation: designing for appropriate reliance. Human Factors, v. 46, n. 1, p. 50-80, 2004. DOI: 10.1518/hfes.46.1.50_30392.

LIPTON, Z. C. The mythos of model interpretability. Communications of the ACM, v. 61, n. 10, p. 36-43, 2018. DOI: 10.1145/3233231.

LOGG, J. M.; MINSON, J. A.; MOORE, D. A. Algorithm appreciation: people prefer algorithmic to human judgment. Organizational Behavior and Human Decision Processes, v. 151, p. 90-103, 2019. DOI: 10.1016/j.obhdp.2018.12.005.

McKENZIE, P. J. Justifying cognitive authority decisions: discursive strategies of information seekers. The Library Quarterly, v. 73, n. 3, p. 261-288, 2003. DOI: 10.1086/603418.

MILELLA, F.; CABITZA, F. Perceiving AI as an epistemic authority or algority: a user study on the human attribution of authority to AI. Machine Learning and Knowledge Extraction, v. 8, n. 2, p. 36, 2026. DOI: 10.3390/make8020036.

MILLER, T. Explanation in artificial intelligence: insights from the social sciences. Artificial Intelligence, v. 267, p. 1-38, 2019. DOI: 10.1016/j.artint.2018.07.007.

MITTELSTADT, B. D.; ALLO, P.; TADDEO, M.; WACHTER, S.; FLORIDI, L. The ethics of algorithms: mapping the debate. Big Data & Society, v. 3, n. 2, p. 1-21, 2016. DOI: 10.1177/2053951716679679.

NANNINI, L. Habemus a right to an explanation: so what? A framework on transparency-explainability functionality and tensions in the EU AI Act. Proceedings of the AAAI/ACM Conference on AI, Ethics, and Society, v. 7, n. 1, p. 1023-1035, 2024. DOI: 10.1609/aies.v7i1.31700.

ÖZER, M.; PERC, M.; ÖZÇELIK, H. T. Human agency and epistemic authority under generative artificial intelligence. Open Praxis, v. 18, n. 3, p. 495-505, 2026. DOI: 10.55982/openpraxis.18.3.1149.

PALESE, R. Artificial truth: algorithmic power, epistemic authority, and the crisis of democratic knowledge. Societies, v. 16, n. 3, p. 102, 2026. DOI: 10.3390/soc16030102.

PARASURAMAN, R.; RILEY, V. Humans and automation: use, misuse, disuse, abuse. Human Factors, v. 39, n. 2, p. 230-253, 1997. DOI: 10.1518/001872097778543886.

PERKINS, M. Academic integrity considerations of AI large language models in the post-pandemic era: ChatGPT and beyond. Journal of University Teaching & Learning Practice, v. 20, n. 2, 2023. DOI: 10.53761/1.20.02.07.

PETERS, M. D. J. et al. Updated methodological guidance for the conduct of scoping reviews. JBI Evidence Synthesis, v. 18, n. 10, p. 2119-2126, 2020. DOI: 10.11124/JBIES-20-00167.

RIEH, S. Y.; DANIELSON, D. R. Credibility: a multidisciplinary framework. Annual Review of Information Science and Technology, v. 41, n. 1, p. 307-364, 2007. DOI: 10.1002/aris.2007.1440410114.

RIEH, S. Y. Judgment of information quality and cognitive authority in the Web. Journal of the American Society for Information Science and Technology, v. 53, n. 2, p. 145-161, 2002. DOI: 10.1002/asi.10017.

RUDIN, C. Stop explaining black box machine learning models for high stakes decisions and use interpretable models instead. Nature Machine Intelligence, v. 1, n. 5, p. 206-215, 2019. DOI: 10.1038/s42256-019-0048-x.

SAFAROV, N.; GADZINSKI, G.; SCHLÖGL, S. In AI we trust? Exploring the role of explainable GenAI and expertise in education. Human Factors, v. 68, n. 4, p. 487-503, 2025. DOI: 10.1177/00187208251401773.

SAVOLAINEN, R. Cognitive authority as an instance of informational and expert power. Libri, v. 72, n. 1, p. 1-12, 2022. DOI: 10.1515/libri-2020-0128.

SELBST, A. D.; BAROCAS, S. The intuitive appeal of explainable machines. SSRN Electronic Journal, 2018. DOI: 10.2139/ssrn.3126971.

SHIN, D. Automating epistemology: how AI reconfigures truth, authority, and verification. AI & Society, v. 41, n. 2, p. 1553-1559, 2026. DOI: 10.1007/s00146-025-02560-y.

SKITKA, L. J.; MOSIER, K. L.; BURDICK, M. Does automation bias decision-making? International Journal of Human-Computer Studies, v. 51, n. 5, p. 991-1006, 1999. DOI: 10.1006/ijhc.1999.0252.

STARTARI, A. V. Artificial intelligence and synthetic authority: an impersonal grammar of power. SSRN Electronic Journal, 2025. DOI: 10.2139/ssrn.5258399.

SUN, Y.; XU, C. Hybrid cognitive authority and algorithmic subjectivity: rethinking knowledge management in AI-driven communication. Journal of Knowledge Management, v. 30, n. 8, p. 2741-2766, 2025. DOI: 10.1108/jkm-02-2025-0252.

TRICCO, A. C. et al. PRISMA Extension for Scoping Reviews (PRISMA-ScR): checklist and explanation. Annals of Internal Medicine, v. 169, n. 7, p. 467-473, 2018. DOI: 10.7326/M18-0850.

UNIÃO EUROPEIA. Regulamento (UE) 2016/679 do Parlamento Europeu e do Conselho, de 27 de abril de 2016, relativo à proteção das pessoas singulares no que diz respeito ao tratamento de dados pessoais. Jornal Oficial da União Europeia, L 119, 4 maio 2016.

UNIÃO EUROPEIA. Regulamento (UE) 2024/1689 do Parlamento Europeu e do Conselho, de 13 de junho de 2024, que estabelece regras harmonizadas em matéria de inteligência artificial. Jornal Oficial da União Europeia, L, 12 jul. 2024.

VASCONCELOS, H. et al. Explanations can reduce overreliance on AI systems during decision-making. Proceedings of the ACM on Human-Computer Interaction, v. 7, n. CSCW1, p. 1-38, 2023. DOI: 10.1145/3579605.

WACHTER, S.; MITTELSTADT, B.; FLORIDI, L. Why a right to explanation of automated decision-making does not exist in the General Data Protection Regulation. International Data Privacy Law, v. 7, n. 2, p. 76-99, 2017. DOI: 10.1093/idpl/ipx005.

WILLIAMSON, B.; EYNON, R. Historical threads, missing links, and future directions in AI in education. Learning, Media and Technology, v. 45, n. 3, p. 223-235, 2020. DOI: 10.1080/17439884.2020.1798995.

WILSON, P. Second-hand knowledge: an inquiry into cognitive authority. Westport: Greenwood Press, 1983.

ZAGZEBSKI, L. T. Epistemic authority: a theory of trust, authority, and autonomy in belief. New York: Oxford University Press, 2012. DOI: 10.1093/acprof:oso/9780199936472.001.0001.

ZAWACKI-RICHTER, O.; MARÍN, V. I.; BOND, M.; GOUVERNEUR, F. Systematic review of research on artificial intelligence applications in higher education: where are the educators? International Journal of Educational Technology in Higher Education, v. 16, n. 1, art. 39, 2019. DOI: 10.1186/s41239-019-0171-0.