PROTOCOLO E REGISTRO DA REVISÃO DE ESCOPO

Autoridade sintética na IA generativa e os limites da explicabilidade

Material suplementar do artigo — versão 2.0, de 12 de novembro de 2026

1 Identificação e versão

Quadro A — Controle de versões do protocolo

Versão	Data	Situação	Alterações
1.0	11/11/2026	Registrada antes das buscas definitivas	Versão inicial, com pergunta PCC, critérios de elegibilidade, fontes, limites e procedimentos
1.1	11/11/2026	Registrada antes da execução	Substituição da Web of Science pela OpenAlex como fonte bibliográfica internacional, por indisponibilidade de assinatura institucional
1.2	11/11/2026	Registrada após as buscas-piloto	Redução do limite de exame por consulta no Google Acadêmico de vinte para dez resultados, em razão de bloqueio por captcha; registro da busca nominal dirigida a obras fundacionais
2.0	12/11/2026	Registrada após a execução	Execução da Web of Science Core Collection, com acesso institucional, em sete consultas (1.407 registros); consolidação do fluxo em 2.658 registros identificados, 372 duplicatas e 2.286 registros triados, com 57 estudos incluídos

2 Pergunta e estrutura PCC

Pergunta de revisão: como a literatura sobre autoridade cognitiva e autoridade epistêmica ajuda a compreender a autoridade atribuída à IA generativa, e em que condições a explicabilidade permite examinar e contestar suas respostas?

Pergunta de abertura do artigo: quando uma resposta gerada por IA deixa de ser apenas uma informação a considerar e passa a funcionar, para o usuário, como razão suficiente para acreditar em algo?

Quadro B — Estrutura população, conceito e contexto (PCC)

Elemento	Definição operacional
População	Usuários de IA generativa e de sistemas automatizados de informação e decisão, em práticas informacionais de trabalho, estudo e uso cotidiano
Conceito	Autoridade cognitiva; autoridade epistêmica; autoridade sintética; credibilidade; confiança; dependência excessiva; viés de automação; heurística da máquina; explicabilidade; interpretabilidade; transparência; contestabilidade
Contexto	IA generativa e modelos de linguagem; apoio à decisão; práticas informacionais em organizações e plataformas

3 Critérios de elegibilidade

Idiomas: português, inglês e espanhol. **Período**: 1983 a 2026, adotando-se 1983 como marco por ser o ano da obra fundacional de Wilson. **Tipos incluídos**: artigo revisado por pares, capítulo de livro, tese ou dissertação, trabalho em anais e preprint com contribuição teórica.

Quadro C — Critérios de inclusão e exclusão

Código	Critério
I1	Discute autoridade cognitiva, epistêmica ou autoridade atribuída a sistemas
I2	Discute credibilidade, confiança, viés de automação ou dependência excessiva
I3	Discute explicabilidade, interpretabilidade, transparência ou contestabilidade
I4	Trata de IA generativa, modelos de linguagem ou automação em informação e decisão
I5	Publicado em português, inglês ou espanhol
I6	Publicado entre 1983 e 2026
I7	Pertence a um dos tipos de publicação admitidos
I8	Texto completo ou resumo acessível
E1	Tema não central para a pergunta de revisão
E2	Contribuição apenas técnica, sem discussão sobre autoridade, explicação ou uso
E3	Duplicata
E4	Sem texto ou resumo acessível
E5	Metadados não verificáveis (veículo, autoria ou data)
E6	Comentário, divulgação ou editorial sem argumentação teórica

4 Fontes, expressões e limites de recuperação

As buscas foram organizadas em três frentes: fundamentos da autoridade; autoridade atribuída à IA; explicabilidade e contestação. Cada expressão foi adaptada à sintaxe da fonte após buscas-piloto. O Quadro D registra as consultas executadas, com data, expressão exata, campos, filtros, ordenação, total exibido e números efetivamente recuperados e examinados.

Quadro D — Consultas executadas em 11 e 12 de novembro de 2026

Fonte	ID	Expressão exata	Campos	Filtros	Ordenação	Total	Recup.	Exam.
BRAPCI	B1	"autoridade cognitiva"	livre	1972-2026	relevância	9	9	9
BRAPCI	B2	"autoridade epistêmica"	livre	1972-2026	relevância	8	8	8
BRAPCI	B3	"autoridade sintética"	livre	1972-2026	relevância	0	0	0
BRAPCI	B4	autoridade AND "inteligência artificial"	livre	1972-2026	relevância	7	7	7
BRAPCI	B5	"explicabilidade" AND "inteligência artificial"	livre	1972-2026	relevância	5	5	5
BRAPCI	B6	"direito à explicação"	livre	1972-2026	relevância	0	0	0
BRAPCI	B8	"competência crítica em informação" AND "inteligência artificial"	livre	1972-2026	relevância	1	1	1
BRAPCI	B9	"desinformação" AND "autoridade"	livre	1972-2026	relevância	18	18	18
OpenAlex	O1	"cognitive authority"	título+resumo	idioma	relevancia	410	200	200
OpenAlex	O2	"epistemic authority" AND ("artificial intelligence" OR "generative AI" OR algorithm)	título+resumo	idioma	relevancia	589	200	200
OpenAlex	O3	"synthetic authority"	título+resumo	idioma	relevancia	29	29	29
OpenAlex	O4	("generative AI" OR "large language model" OR ChatGPT) AND (authority OR deference)	título+resumo	idioma	relevancia	4343	200	200
OpenAlex	O5	"right to explanation" AND (explainable OR XAI OR contestability)	título+resumo	idioma	relevancia	190	190	190
OpenAlex	O7	"automation bias" AND ("large language model" OR "generative AI" OR "clinical decision")	título+resumo	idioma	relevancia	671	200	200
OpenAlex	O8	"machine heuristic"	título+resumo	nenhum	relevância	114	0	0
Web of Science	W1	("cognitive authority")	tópico (TS)	nenhum	relevância	175	175	175
Web of Science	W2	("epistemic authority") AND ("artificial intelligence" OR "generative AI" OR algorithm)	tópico (TS)	nenhum	relevância	141	141	141
Web of Science	W3	("synthetic authority")	tópico (TS)	nenhum	relevância	0	0	0
Web of Science	W4	("generative AI" OR "large language model" OR "large language models" OR ChatGPT) AND (authority OR deference)	tópico (TS)	nenhum	relevância	742	742	742
Web of Science	W5	("right to explanation") AND (explainable OR XAI OR contestability)	tópico (TS)	nenhum	relevância	31	31	31
Web of Science	W6	("automation bias") AND ("large language model" OR "large language models" OR "generative AI" OR "clinical decision")	tópico (TS)	nenhum	relevância	245	245	245
Web of Science	W7	("machine heuristic")	tópico (TS)	nenhum	relevância	73	73	73
Google Acadêmico	G1	"cognitive authority"	livre	idioma	relevância	≈9.990	10	10
Google Acadêmico	G2	"epistemic authority" "artificial intelligence"	livre	idioma	relevância	≈9.950	10	10
Google Acadêmico	G3	"synthetic authority"	livre	idioma	relevância	≈155	10	10
Google Acadêmico	G4	"generative AI" deference authority	livre	idioma	relevância	≈20.900	10	10
Google Acadêmico	G5	"right to explanation" "explainable AI"	livre	idioma	relevância	≈6.690	10	10
Google Acadêmico	G6	"autoridade cognitiva"	livre	idioma	relevância	≈651	10	10
Google Acadêmico	G7	"explicabilidade" "inteligência artificial"	livre	idioma	relevância	≈5.090	10	10
Rastreamento	R1	citações de Hirvonen; Multas; Nygård (2025)	citações	por ano	ano	13	13	13
Rastreamento	R2	referências de Hirvonen; Multas; Nygård (2025)	referências	por citações	citações	13	13	13
Rastreamento	R3	citações de Wachter; Mittelstadt; Floridi (2017)	citações	por ano	ano	1822	40	40
Rastreamento	R4	referências de Wachter; Mittelstadt; Floridi (2017)	referências	por citações	citações	1822	40	40

Limites definidos a priori: no Google Acadêmico, exame dos 20 primeiros resultados por consulta, reduzido a 10 por bloqueio automatizado; na OpenAlex, 200 registros por consulta, ordenados por relevância; na BRAPCI, recuperação integral dos resultados. **Web of Science**: executada em 12/11/2026, com acesso institucional pelo

Portal de Periódicos da CAPES, em sete consultas no campo TS, que somaram 1.407 registros. **Busca complementar**: rastreamento de citações e de referências a partir de duas sementes, e busca nominal dirigida a obras fundacionais.

5 Triagem, extração e síntese

A deduplicação foi feita por identificador digital e, na ausência dele, por similaridade entre títulos normalizados. A triagem de títulos e resumos aplicou os critérios E1 a E6, em etapa automática de regras e pontuação de pertinência e em etapa manual. Os textos completos foram avaliados quando acessíveis; quando o acesso era restrito, avaliou-se o resumo, e as afirmações atribuídas ao estudo se limitam ao que o resumo permite verificar. A extração foi registrada em planilha com os campos: referência, contexto, tipo de estudo, conceitos, definições, achados, limitações, localização exata da evidência e afirmação sustentada no artigo.

A síntese foi narrativa, organizada por frentes temáticas, com quadro comparativo das três formas de autoridade. Não houve avaliação formal de qualidade metodológica, o que é compatível com revisões de escopo, mas impede ponderação dos achados por robustez.

Quadro E — Fluxo de seleção e conferência de contagens

Etapa	Bases bibliográficas	Fontes complementares	Total
Registros identificados	2.474	184	2.658
Duplicatas removidas	359	13	372
Registros triados	2.115	171	2.286
Excluídos na triagem	2.061	168	2.229
Estudos incluídos	54	3	57

Conferência: 2.115 − 2.061 = 54; 171 − 168 = 3; 54 + 3 = 57. As contagens coincidem com as abas de triagem, leitura integral e extração da planilha auditável. Os 184 registros complementares correspondem a 70 examinados no Google Acadêmico, 106 no rastreamento de citações e 8 recuperados por busca nominal dirigida. As bases bibliográficas somam 2.474 registros: 48 na BRAPCI, 1.019 na OpenAlex e 1.407 na Web of Science.

6 Registro de decisões e restrições declaradas

Quadro F — Restrições declaradas

Item	Situação	Efeito sobre a síntese
Web of Science	Executada em 12/11/2026, com acesso institucional (sete consultas, 1.407 registros)	Cobertura ampliada; a expressão synthetic authority não retornou registros, o que reforça a leitura de rótulo incipiente
Google Acadêmico	Executada com captcha; exame de 10 resultados por consulta	Limite de recuperação; parte dos textos fundacionais obtida por busca nominal dirigida
OpenAlex, consulta O8	Consulta executada (114 registros), exportação falhou	Registros não entraram na triagem; consulta registrada como pendente de recuperação
Revisores	Um revisor, sem dupla triagem independente	Risco de erro de seleção não estimado
Acesso a textos	45 dos 57 estudos avaliados apenas por resumo	Afirmações limitadas ao que o resumo permite verificar
Qualidade metodológica	Não avaliada formalmente	Achados não ponderados por robustez

7 Reprodutibilidade

Os arquivos que acompanham este protocolo permitem refazer cada etapa: o registro bruto das buscas, o conjunto deduplicado, a lista de triagem com decisão e motivo, a lista de textos avaliados, a matriz de extração com localização da evidência e os scripts de coleta, deduplicação, verificação de metadados e geração das figuras. A planilha auditável reúne esses registros em abas separadas e conciliadas com o Quadro E.